Ensamble learning

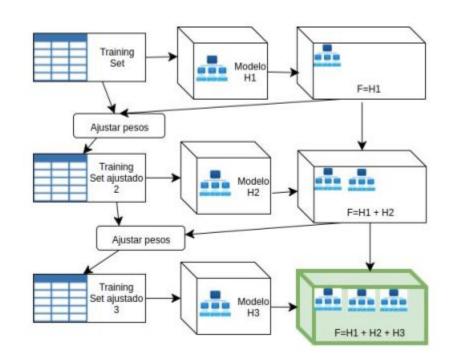
Diplomatura en Ciencias Sociales Computacionales

Repasando...

- Para superar las limitaciones de los árboles de decisión, existen:
 - Métodos de averaging:
 - Basados en construir estimadores independientes y luego promediar las predicciones.
 - Reducen la varianza de cualquier método de aprendizaje estadístico.
 - Ejs: Bagging, Random Forest, Extra Random Trees
 - Métodos de boosting
 - Los estimadores de base se construyen secuencialmente y se trata de reducir el sesgo del estimador combinado.
 - Ejs: ADABoosting, Gradient Boosting

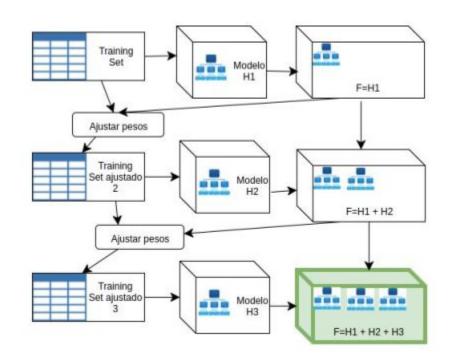
Boosting

- Meta-algoritmo: procedimiento iterativo → el modelo final se construye por pasos
- Aprender de los errores cometidos en los pasos previos
- Sobre los errores del modelo anterior:
 - cambiar la ponderación en el siguiente modelo
 - entrenando un modelo que prediga los mismos.



AdaBoost

- 1 iteración: pesos uniformes para todos los registros. Luego, los pesos se ajustan para enfatizar los errores en la iteración anterior
- Predicción final: voto ponderado según cada error de entrenamiento, de los distintos modelos base
- Modelo base débil →re-entrenarlo en las muestras mal clasificadas



Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights $w_i = 1/N, i = 1, 2, ..., N$.

$$\operatorname{err}_m = \frac{\sum_{i=1}^{M} x_i^{i}}{x_i^{i}}$$

- 1. Se inicializan todos los pesos iguales.
- 2. For m=1 to M:

 (a) Fit a classifier $G_m(x)$ to the distribution $G_m(x)$ to the distribution Habrá un **peso Wi** asociado a **cada uno de los** ejemplos (Xi) del set de entrenamiento.
 - N representa la cantidad de ejemplos en el set de

$$\sum_{i=1}^{n} w_i$$

- (c) Compute $\alpha_m = \log((1 \text{err}_m)/\text{err}_m)$.
- (d) Set $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))], i = 1, 2, \dots, N$.
- 3. Output $G(x) = \operatorname{sign} \left[\sum_{m=1}^{M} \alpha_m G_m(x) \right]$.

Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights $w_i = 1/N, i = 1, 2, ..., N$.
- 2. For m = 1 to M:
 2. El algoritmo entrenará **M** clasificadores.
 - (a) Fit a classifier $G_m(x)$ to the training data using weights w_i .
 - (b) Compute

$$err_m = \frac{\sum_{i=1}^{N} w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^{N} w_i}.$$

- (c) Compute $\alpha_m = \log((1 \operatorname{err}_m)/\operatorname{err}_m)$.
- (d) Set $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))], i = 1, 2, \dots, N.$
- 3. Output $G(x) = \operatorname{sign} \left[\sum_{m=1}^{M} \alpha_m G_m(x) \right]$.

Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights $w_i = 1/N, i = 1, 2, ..., N$.
- 2. For m=1 to M:
 - (a) Fit a classifier $G_m(x)$ to the training data using weights w_i .
 - (b) Compute

(b) Compute
$$\operatorname{err}_m = \frac{\sum_{i=1}^N w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i I(y_i \neq G_m(x_i))}$$
 2.a. Se entrena el clasificador Gm, considerando el set de entrenamiento y el peso wi asignado a cada uno de los ejemplos.

- (d) Set $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))], i = 1, 2, \dots, N$.
- 3. Output $G(x) = \operatorname{sign} \left[\sum_{m=1}^{M} \alpha_m G_m(x) \right]$.

Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights $w_i = 1$
- 2. For m = 1 to M:
 - (a) Fit a classifier $G_m(x)$ to the training with $G_m(x)$ to the training with $G_m(x)$
 - (b) Compute

$$err_m = \frac{\sum_{i=1}^{N} w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^{N} w_i}.$$

- (c) Compute $\alpha_m = \log((1 \text{err}_m)/\text{err}_m)$.
- (d) Set $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))], i = 1, 2, \dots, N.$
- 3. Output $G(x) = \operatorname{sign} \left[\sum_{m=1}^{M} \alpha_m G_m(x) \right]$.

2.b. Se calcula el **error de clasificación** ponderado de Gm.

ERRm será la suma del peso de los ejemplos mal clasificados / suma todos los pesos

- Mínimo de 0 cuando no haya errores.
- Máximo de 1 cuando sean todos errores.
- Los ejemplos de alto peso mal clasificados influyen más que los de pesos bajos.

Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights w_i
- 2. For m = 1 to M:
 - (a) Fit a classifier $G_m(x)$ to the tra
 - (b) Compute

2.c. Se calcula el **coeficiente de aporte** de este **Clasificador en el ensamble**.

El valor será mayor cuanto más preciso sea el clasificador Gm, dándole mayor importancia a su voto en el comité.

$$\operatorname{err}_{m} = \frac{\sum_{i=1}^{N} w_{i} \overline{I(y_{i} \neq G_{m}(x_{i}))}}{\sum_{i=1}^{N} w_{i}}.$$

- (c) Compute $\alpha_m \Rightarrow \log((1 \operatorname{err}_m)/\operatorname{err}_m)$.
- (d) Set $w_i \leftarrow \widetilde{w_i} \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))], i = 1, 2, \dots, N.$
- 3. Output $G(x) = \text{sign}\left[\sum_{m=1}^{M} \alpha_m G_m(x)\right]$

Este coeficiente es el que determina el peso del voto de este clasificador en el comité resultante.

Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights $w_i = 1/N$, i
- 2. For m = 1 to M:
 - (a) Fit a classifier $G_m(x)$ to the training data
 - (b) Compute

$$err_m = \frac{\sum_{i=1}^{N} w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^{N} w_i}.$$

- (c) Compute $\alpha_m = \log((1 \text{err}_m)/\text{err}_m)$
- (d) Set $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))], i = 1, 2, \dots, N.$
- 3. Output $G(x) = \operatorname{sign} \left[\sum_{m=1}^{M} \alpha_m G_m(x) \right]$.

2.d. Se **recalculan** los pesos de los ejemplos del set de entrenamiento.

Aumentando los pesos de aquellos ejemplos mal clasificados

Algorithm 10.1 AdaBoost.M1.

- 1. Initialize the observation weights $w_i = 1/N, i = 1, 2, ..., N$.
- 2. For m=1 to M:
 - (a) Fit a classifier $G_m(x)$ to the training d
 - (b) Compute

3. Se obtiene como resultado el ensamble G(x) donde cada Gm(x) hace su aporte con su voto ponderado por su coeficiente Am.

$$\operatorname{err}_{m} = \frac{\sum_{i=1}^{N} w_{i} I(y_{i} \neq G_{m}(x_{i}))}{\sum_{i=1}^{N} w_{i}}.$$
(c) Compute $\alpha_{m} = \log((1 - \operatorname{err}_{m})/\operatorname{err}_{m}).$
(d) Set $w_{i} \leftarrow w_{i} \cdot \exp[\alpha_{m} \cdot I(y_{i} \neq G_{m}(x_{i}))], \ i = 1, 2, \dots, N.$

- 3. Output $G(x) = \operatorname{sign} \left[\sum_{m=1}^{M} \alpha_m G_m(x) \right]$.

Gradient Boosting

- Generalización de boosting para funciones de pérdida diferenciables.
- Es un procedimiento preciso y efectivo que se puede usar para problemas de regresión y clasificación.
- Modelos de Gradient Boosting de árboles se utilizan en una variedad de áreas, incluyendo ranking de búsqueda web, ecología, etc.

Input: training set $\{(x_i, y_i)\}_{i=1}^n$, a differentiable loss function L(y, F(x)), number of iterations M. Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = rg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma).$$

- 2. For m = 1 to M:
 - 1. Compute so-called pseudo-residuals:

$$r_{im} = -iggl[rac{\partial L(y_i,F(x_i))}{\partial F(x_i)}iggr]_{F(x)=F_{m-1}(x)} \quad ext{for } i=1,\ldots,n.$$

- 2. Fit a base learner (e.g. tree) $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\{(x_i, r_{im})\}_{i=1}^n$.
- 3. Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\gamma_m = rg \min_{\gamma} \sum_{i=1}^n L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)
ight).$$

4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

Input: training set $\{(x_i,y_i)\}_{i=1}^n$, a differentiable loss function L(y,F(x)), number of iterations M.

Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = rg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma).$$

Inicializamos el modelo con un valor constante.

- 2. For m = 1 to M:
 - 1. Compute so-called pseudo-residuals:

$$r_{im} = -iggl[rac{\partial L(y_i,F(x_i))}{\partial F(x_i)}iggr]_{F(x)=F_{m-1}(x)} \quad ext{for } i=1,\ldots,n.$$

- 2. Fit a base learner (e.g. tree) $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\{(x_i, r_{im})\}_{i=1}^n$.
- 3. Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\gamma_m = rg \min_{\gamma} \sum_{i=1}^n L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)
ight).$$

4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

Input: training set $\{(x_i, y_i)\}_{i=1}^n$, a differentiable loss function L(y, F(x)), number of iterations M. Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = rg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma).$$

2. For m = 1 to M:

1. Compute so-called pseudo-residuals:

$$r_{im} = -iggl[rac{\partial L(y_i,F(x_i))}{\partial F(x_i)}iggr]_{F(x)=F_{m-1}(x)} \quad ext{for } i=1,\ldots,n.$$

Para cada iteración computamos los valores residuales.

- 2. Fit a base learner (e.g. tree) $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\{(x_i, r_{im})\}_{i=1}^n$.
- 3. Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\gamma_m = rg \min_{\gamma} \sum_{i=1}^n L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)
ight).$$

4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

Input: training set $\{(x_i, y_i)\}_{i=1}^n$, a differentiable loss function L(y, F(x)), number of iterations M. Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = rg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma).$$

- 2. For m = 1 to M:
 - 1. Compute so-called pseudo-residuals:

$$r_{im} = -iggl[rac{\partial L(y_i, F(x_i))}{\partial F(x_i)}iggr]_{F(x) = F_{m-1}(x)} \quad ext{for } i = 1, \dots, n.$$

- 2. Fit a base learner (e.g. tree) $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\{(x_i, r_{im})\}_{i=1}^n$.
- Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\gamma_m = rg \min_{\gamma} \sum_{i=1}^n L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)
ight).$$

4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

3. Output $F_M(x)$.

Para cada iteración (m=1 to M) fiteamos un modelo (por ejemplo, un árbol de decisión) sobre los residuos sobre el training set

Input: training set $\{(x_i, y_i)\}_{i=1}^n$, a differentiable loss function L(y, F(x)), number of iterations M. Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = rg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma).$$

- 2. For m = 1 to M:
 - 1. Compute so-called pseudo-residuals:

$$r_{im} = -iggl[rac{\partial L(y_i,F(x_i))}{\partial F(x_i)}iggr]_{F(x)=F_{m-1}(x)} \quad ext{for } i=1,\ldots,n.$$

Lo que se busca es encontrar el valor de gamma, que permite calcular la contribución de cada modelo

- 2. Fit a base learner (e.g. tree) $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\{(x_i, r_{im})\}_{i=1}^n$.
- 3. Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\gamma_m = rg \min_{\gamma} \sum_{i=1}^n L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)
ight).$$

4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

Input: training set $\{(x_i, y_i)\}_{i=1}^n$, a differentiable loss function L(y, F(x)), number of iterations M. Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = rg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma).$$

- 2. For m = 1 to M:
 - 1. Compute so-called pseudo-residuals:

$$r_{im} = -iggl[rac{\partial L(y_i,F(x_i))}{\partial F(x_i)}iggr]_{F(x)=F_{m-1}(x)} \quad ext{for } i=1,\ldots,n.$$

- 2. Fit a base learner (e.g. tree) $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\{(x_i, r_{im})\}_{i=1}^n$
- 3. Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\gamma_m = rg \min_{\gamma} \sum_{i=1}^n L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)
ight).$$

4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

3. Output $F_M(x)$.

Actualizamos el modelo agregando el learner nuevo a la predicción